

基于演化计算的 TSP 问题求解与性能分析

—— 以中国 34 个省会城市为例

一、引言

1.1 国内外研究背景

旅行商问题 (Traveling Salesman Problem, TSP) 是经典的组合优化 NP 难问题, 其目标是寻找一条遍历所有城市且仅访问一次、最终返回起点的最短闭合路径。由于 TSP 在物流配送、路径规划、集成电路设计等领域的广泛应用, 求解 TSP 的高效算法一直是研究热点。

传统精确算法 (如动态规划、分支定界) 在城市规模较小时有效, 但随着城市数量增加, 计算复杂度呈指数级增长, 难以处理大规模 TSP。演化计算作为一类启发式优化方法, 通过模拟自然进化或群体智能过程实现全局优化, 成为求解 TSP 的主流技术。其中:

1. 遗传算法 (Genetic Algorithm, GA) 通过选择、交叉、变异模拟生物进化, 在 TSP 中已形成成熟的排列编码和交叉变异策略;
2. 粒子群优化 (Particle Swarm Optimization, PSO) 通过粒子位置和速度更新实现搜索, 但需针对 TSP 的离散特性改进操作算子;
3. 蚁群算法 (Ant Colony Optimization, ACO) 模拟蚂蚁觅食的信息素机制, 在 TSP 中表现出良好的全局搜索能力;
4. 差分进化 (Differential Evolution, DE) 通过差分变异和交叉生成新解, 近年也被扩展到离散组合优化问题。

国内外学者针对 TSP 的演化计算改进主要集中在算子设计 (如 GA 的部分映射交叉、PSO 的离散速度定义)、参数自适应调整、混合策略等方向, 但不同算法在中小规模 TSP 中的性能对比仍需具体验证。

1.2 本文框架

本文采用 GA、PSO、ACO、DE 四种演化计算算法求解中国 34 个省会城市的 TSP 问题, 对比分析算法的最优解质量、收敛速度及参数敏感性。全文结构如下: 第二部分介绍实验方法 (算法原理、编码方式、数据集及目标函数); 第三部分展示实验结果并分析; 第四部分总结结论。

二、实验方法

2.1 数据集

实验采用中国 34 个省会及直辖市的经纬度数据，存储于 distanceMatrix.txt 文件，每行包含城市名、经度、纬度，共 34 个城市节点。

2.2 目标函数

TSP 的目标是最小化路径总距离，定义路径总距离为：

$$D = \sum_{i=1}^{n-1} \sqrt{\{(x_i - x_{i+1})^2 + (y_i - y_{i+1})^2\}} + \sqrt{\{(x_n - x_1)^2 + (y_n - y_1)^2\}}$$

其中 x_i 为第 i 个城市的经度， y_i 为第 i 个城市的纬度。为适应演化算法的最大化优化目标，将适应度函数定义为总距离的倒数：

$$\text{Fitness} = 1 / \max(D, 10^{-12})$$

2.3 算法原理与实现

2.3.1 遗传算法（GA）

编码方式：整数排列编码，每个个体为城市索引的排列（如[5,1,3,...]表示依次访问第 5、1、3 个城市）；

操作流程：

选择：轮盘赌选择，根据适应度分配选择概率；

交叉：部分区间交叉，保留父代部分区间，其余位置由另一父代填充；

变异：逆序变异，随机选择区间并反转；

参数设置：种群规模 100，交叉率 0.6，变异率 0.03，最大迭代 2000 代。

2.3.2 粒子群优化（PSO）

离散化编码：

粒子编码：城市索引排列；

速度定义：交换操作集合；

位置更新：应用速度中的交换操作生成新路径；

算法策略：

邻域初始化：部分粒子采用贪心策略初始化，提升初始解质量；

惯性权重：线性递减（0.9→0.4），平衡全局与局部搜索；

精英保留：保留全局最优解，防止退化；

参数设置：种群规模 100，学习因子 $c_1 = c_2 = 1.4$ ，最大迭代 3000 代。

2.3.3 蚁群算法 (ACO)

核心机制：

信息素矩阵：初始化全为 0.5，记录城市间路径的吸引力；

状态转移概率：结合信息素浓度和启发式信息；

信息素更新：挥发与更新

参数设置：蚂蚁数量 40，信息素权重，启发式权重，最大迭代 200 代。

2.3.4 差分进化 (DE)

离散化改进：

变异操作：随机选择个体进行交换变异生成突变体；

交叉操作：部分映射交叉 (PMX)，保留父代与突变体的有效基因；

参数设置：种群规模 80，差分因子，交叉率，最大迭代 1000 代。

三、实验结果与分析

3.1 算法性能对比

实验独立运行 5 次，取最优值、平均值及收敛迭代次数，结果如表 1 所示：

算法	最优路径距离 (km)	平均路径距离 (km)	平均收敛迭代次数
GA	157.270609	169.2210912	1786.6
PSO	154.778997	160.5188922	1513
ACO	157.77796	158.5884232	103.2
DE	179.589875	185.0558224	404.2

3.2 实验结果分析

基于 5 次独立实验数据，从解质量、稳定性、收敛速度三个核心维度分析如下：

(1) 解质量方面，PSO 最优，DE 最差

四种算法最优解排序：PSO (154.78 km) > GA (157.27 km) ≈ ACO (157.78 km) > DE (179.59 km)。PSO 凭借“个体最优 + 全局最优”双引导机制，最优解较次优的 GA 领先 2.49 km，全局搜索效率最高；GA 与 ACO 解质量接近，差距仅 0.5 km；DE 因离散算子适配性不足，最优解落后 PSO 约 24.8 km，表现显著不佳。

(2) 稳定性方面，ACO 最优，DE 最差

结合偏差与平均距离判断，ACO 偏差 0.81 km，平均距离 158.59 km，稳定性最强；PSO 偏差 5.74 km，平均距离 160.52 km，稳定性次之；GA：偏差 11.95 km，平均距离 169.22 km，稳定性一般；DE 虽偏差仅 5.46 km，但平均距离 185.05 km 远高于其他算法，综合稳定性最差。

(3) 收敛速度方面，ACO 最优

收敛效率排序：ACO (103.2 代) > DE (404.2 代) > PSO (1513 代) > GA (1786.6 代)

ACO 借助信息素正反馈机制，收敛速度是 GA 的 17 倍；DE 差分变异生成新解效率高，收敛快于 GA、PSO；而 GA、PSO 需多代迭代平衡探索与精炼，收敛较慢。

四、结论

本文通过 GA、PSO、ACO、DE 四种演化计算算法求解中国 34 个省会城市 TSP 问题，基于 5 次独立实验的统计结果，得出以下结论：

- 1. 算法性能差异显著：**ACO 展现出最优的综合实用性，在稳定性（偏差 0.81 km）和收敛速度（103.2 代）上表现碾压式领先，解质量（157.78 km）虽略逊于 PSO 但完全满足实际需求；PSO 的核心优势是解质量最优（154.78 km），但收敛速度较慢（1513 代），适合对解精度要求高、可接受长计算时间的场景；GA 综合表现中等，解质量与 ACO 接近但稳定性和收敛速度不足；DE 因离散算子与 TSP 适配性差，在解质量（179.59 km）和综合稳定性上表现最差，需进一步优化。
- 2. 算法适配性与机制密切相关：**ACO 的信息素正反馈与动态平衡机制，使其天然适配 TSP 的路径搜索特性；PSO 的双引导更新策略提升了最优解挖掘能力，但需在探索与精炼间权衡导致收敛较慢；GA 的遗传操作随机性易引发解波动，DE 的连续优化原生机制难以适配离散排列编码，均限制了各自性能。
- 3. 应用场景与改进方向明确：**实际应用中，若需快速获取稳定可靠的路径方案，优先选择 ACO；若追求极致的最短路径，可选用 PSO 并适当延长迭代次数；GA 可通过动态调整交叉率、变异率优化稳定性，DE 需重新设计离散化算子（如结合贪心策略）提升适配性。未来可进一步探索混合算法（如 ACO-PSO 融合），兼顾收敛速度与解质量，提升复杂 TSP 问题的求解性能。